



TRABAJO FIN DE GRADO
GRADO EN INGENIERÍA INFORMÁTICA

Clasificación de galaxias mediante Deep Learning

Autor

Jorge Picado Cariño

Director

Julián Luengo Martín



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

—
Granada, julio de 2023



Clasificación de galaxias mediante Deep Learning

Autor

Jorge Picado Cariño

Director

Julián Luengo Martín

Clasificación de galaxias mediante Deep Learning

Jorge Picado Cariño

Palabras clave: galaxias, segmentación de imágenes, clasificación de imágenes, Deep Learning, Aprendizaje Supervisado, Aprendizaje No Supervisado, Visión por Computador

Resumen

En las últimas décadas, el campo de la astronomía ha experimentado un crecimiento exponencial gracias a los avances en la tecnología y el acceso a grandes volúmenes de datos. Uno de los aspectos que engloba la astronomía es el estudio de las galaxias, que son agrupaciones de estrellas, cuerpos celestes y materia cósmica que está concentrada en una determinada región del espacio por efecto de la atracción gravitatoria y constituye una unidad en el universo.

La clasificación de galaxias es una tarea fundamental en la astronomía, ya que permite comprender mejor la formación y evolución del universo. Tradicionalmente, esta clasificación se ha llevado a cabo de manera manual por astrónomos expertos, quienes examinan imágenes de galaxias y las categorizan en diferentes tipos según su forma, estructura y otras características observables.

Sin embargo, debido al crecimiento exponencial de los datos astronómicos, se requiere de métodos más eficientes y automatizados para clasificar las galaxias de manera precisa y rápida. En cada imagen del espacio de un telescopio pueden aparecer decenas de galaxias. La tarea de los astrónomos especializados en su clasificación (espiral, elíptica, etc.) puede suponer un tiempo considerable que tiene un coste económico perceptible y una merma de otras tareas que el experto podría estar realizando. En este contexto, el aprendizaje profundo, o "Deep Learning", ha demostrado ser una herramienta poderosa y prometedora.

Se espera que este enfoque de clasificación automatizada de galaxias mediante Deep Learning proporcione resultados eficientes en comparación con los métodos tradicionales. Además, el sistema desarrollado podría utilizarse como una herramienta complementaria para los astrónomos, ayudándoles a procesar grandes volúmenes de datos y acelerar el proceso de clasificación.

El objetivo de este Trabajo de Fin de Grado (TFG) es el uso de técnicas de Deep Learning para segmentar las galaxias de las imágenes astronómicas, así como clasificar su forma si la resolución es suficiente. Se planteará el uso de técnicas supervisadas frente a no supervisadas para ahorrar el máximo tiempo al posible astrónomo experto. Para lograr esto, se utilizarán conjuntos de datos astronómicos que contienen imágenes de galaxias previamente clasificadas, este dataset está disponible en el proyecto Galaxy Zoo. Estas imágenes serán utilizadas para entrenar un modelo que aprenderá a reconocer los patrones y características distintivas de cada tipo de galaxia.

En resumen, este TFG tiene como objetivo principal la clasificación automatizada de galaxias mediante el uso de técnicas de Deep Learning. Se espera que los resultados obtenidos contribuyan al avance del campo de la astronomía y abran nuevas puertas para la exploración y comprensión del universo.

Classification of Galaxies Using Deep Learning

Jorge Picado Cariño

Keywords: galaxies, image segmentation, image classification, Deep Learning, Supervised Learning, Unsupervised Learning, Computer Vision

Abstract

Write here the abstract in English.

Yo, **Jorge Picado Cariño**, alumno de la titulación Grado en Ingeniería Informática de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 75930960W, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Jorge Picado Cariño

Granada a X de julio de 2023.

D. **Julián Luengo Martín**, Profesor del Área de XXXX del Departamento Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

Informa:

Que el presente trabajo, titulado ***Clasificación de galaxias mediante Deep Learning***, ha sido realizado bajo su supervisión por **Jorge Picado Cariño**, y autorizo la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a X de julio de 2023.

El director:

Julián Luengo Martín

Agradecimientos

Quiero agradecer a todas las personas que me han apoyado en la realización de mi Trabajo de Fin de Grado, gracias a ellos este logro no hubiera sido posible.

En primer lugar a mi tutor académico Julián, por su orientación, apoyo y valiosos consejos a lo largo de todo el proceso de elaboración de este trabajo.

A mis compañeros y compañeras de clase, por su colaboración, intercambio de ideas y apoyo mutuo. Fue enriquecedor poder contar con sus opiniones y consejos no sólo durante este trabajo, sino a lo largo de estos 4 años.

A mi familia, por su amor, paciencia y comprensión a lo largo de toda mi etapa académica. Su apoyo incondicional me impulsó a alcanzar mis metas.

Sin todas estas personas, este Trabajo de Fin de Grado no hubiera sido posible. Les estoy profundamente agradecido por su tiempo, esfuerzo y dedicación.

Índice general

1. Introducción	19
1.1. Motivación	20
1.2. Objetivos	21
1.3. Presupuesto	21
1.4. Planificación	21
2. Estado del Arte y Conceptos	23
2.1. Visión por Computador	24
2.2. Clasificación de imágenes	25
2.3. Segmentación de imágenes	26
2.4. Conceptos básicos Deep Learning	27
2.4.1. Redes Neuronales Convolucionales (CNN)	27
2.4.2. Capas de pooling	27
2.4.3. Transferencia de aprendizaje	29
2.4.4. Aumento de datos	29
2.4.5. Validación cruzada	29
2.4.6. Frameworks y bibliotecas	29
2.5. Aprendizaje Supervisado	29

2.6. Aprendizaje No Supervisado	30
3. Análisis	33
3.1. Dataset	34
3.1.1. Conjunto de imágenes	35
3.1.2. Archivo CSV	35
3.1.3. Archivo json	36
3.2.	37

Índice de figuras

1.1. Ejemplar de tigre de Bengala	20
1.2. Diagrama de Gantt	22
2.1. Ejemplo de detección de objetos	24
2.2. Ejemplo de segmentación semántica	25
2.3. Ejemplo de Average Pooling	28
2.4. Ejemplos de patrones (imagen, dígito)	30
2.5. Ejemplo de aprendizaje no supervisado	31
3.1. Ejemplos de imágenes de galaxias extraídas de Galaxy Zoo .	34
3.2. Ejemplo de imagen y su correspondiente máscara	36

Índice de cuadros

Capítulo 1

Introducción

En los últimos años, el campo de la astronomía ha experimentado avances significativos gracias al uso de técnicas de aprendizaje automático, en particular el aprendizaje profundo (Deep Learning). Estas técnicas han demostrado ser eficaces en diversas tareas, entre ellas el tema del presente trabajo, la clasificación de galaxias, un campo de estudio fundamental para comprender la evolución y la estructura del universo.

El aprendizaje profundo se basa en redes neuronales artificiales de múltiples capas, que son capaces de aprender representaciones de alto nivel a partir de datos sin procesar. En el contexto de la astronomía, estas redes neuronales pueden analizar grandes volúmenes de datos astronómicos, como imágenes de telescopios, espectros y curvas de luz, para extraer patrones complejos y realizar tareas de clasificación, detección y predicción.

Varios estudios han demostrado la eficacia del aprendizaje profundo en la clasificación de galaxias. Por ejemplo, en el trabajo de Dieleman et al. (2015), se utilizó una red neuronal convolucional para clasificar automáticamente imágenes de galaxias del Sloan Digital Sky Survey (SDSS) en diferentes categorías morfológicas. Los resultados mostraron que el enfoque de aprendizaje profundo superó a los métodos tradicionales de clasificación realizados por expertos astrónomos.

Otro ejemplo relevante es el trabajo de Huertas-Company et al. (2015), donde se utilizó una red neuronal profunda para clasificar galaxias según su evolución. El modelo fue capaz de identificar características sutiles en las imágenes galácticas que están relacionadas con la historia de formación estelar de las galaxias, lo que permitió clasificarlas de manera más precisa que los métodos anteriores.

Estos ejemplos demuestran el potencial del aprendizaje profundo en la astronomía y su capacidad para mejorar la eficiencia y la precisión en diversas tareas. A medida que se recopilan más datos astronómicos y se desarrollan nuevas técnicas de aprendizaje profundo, se espera que el campo continúe avanzando y brindando nuevas perspectivas sobre la estructura y evolución del universo.

1.1. Motivación

La clasificación de galaxias tradicionalmente ha sido realizada por astrónomos expertos, quienes analizan y categorizan manualmente las características visuales de las imágenes galácticas. Sin embargo, este enfoque es laborioso, subjetivo y limitado en términos de escala y eficiencia. Aquí es donde entra en juego el poder del aprendizaje profundo, que permite automatizar y mejorar el proceso de clasificación.

En las últimas décadas la cantidad de datos a procesar se ha incrementado exponencialmente. Este número de datos va a seguir aumentando en los próximos años de manera muy significativa, tal y como muestra el siguiente gráfico:




Figura 1.1: Ejemplar de tigre de Bengala

En resumen, este trabajo se centra en la aplicación de técnicas de Deep Learning para la clasificación de galaxias, para mejorar la eficiencia y la precisión en este proceso fundamental para la astronomía. A través de la combinación de conocimientos en astronomía y aprendizaje automático, se espera aportar avances significativos en este campo y abrir nuevas oportunidades de investigación.

1.2. Objetivos

En este Trabajo de Fin de Grado (TFG), nos proponemos abordar el desafío de la clasificación de galaxias utilizando técnicas de Deep Learning. El objetivo principal es desarrollar un modelo de clasificación preciso y eficiente que pueda analizar grandes conjuntos de datos astronómicos y asignar de manera automática las galaxias a diferentes categorías.

Para lograr este objetivo, se emplearán redes neuronales convolucionales (CNN) y otras técnicas de Deep Learning, que han demostrado su eficacia en la clasificación de imágenes. Estas técnicas permitirán extraer características relevantes de las imágenes galácticas y aprender patrones complejos que son difíciles de discernir para el ojo humano.

Además, se utilizarán conjuntos de datos astronómicos existentes, que proporcionan una gran cantidad de imágenes galácticas etiquetadas con categorías conocidas. Estos datos serán preprocesados y se dividirán en conjuntos de entrenamiento, validación y prueba, para entrenar y evaluar el modelo propuesto.

Se espera que este trabajo contribuya al avance de la clasificación automatizada de galaxias, permitiendo una mayor eficiencia en la investigación astronómica y facilitando el análisis de grandes volúmenes de datos.

1.3. Presupuesto

1.4. Planificación

Con el fin de garantizar un progreso adecuado del proyecto y cumplir con la fecha límite establecida, se han identificado las diferentes actividades que deben llevarse a cabo, así como el tiempo estimado para completar cada una de ellas. A continuación, se detallan las tareas identificadas:

- Análisis de las técnicas del estado del arte para clasificación de imágenes de aprendizaje supervisado y aprendizaje no supervisado.
- Estudio de los conjuntos de datos disponibles, recopilación y preparación de datos con el objeto de reunir un conjunto de datos astronómicos que contenga imágenes de galaxias etiquetadas correctamente.
- Preprocesamiento de las imágenes para asegurarse de que estén en

un formato adecuado para el aprendizaje profundo. Esto incluye la normalización, el escalado y la eliminación de ruido.

- Elección de distintos modelos de aprendizaje profundo, se seleccionarán una serie de modelos concretos y se entrenarán utilizando el conjunto de datos recopilado.
- Evaluación de los modelos analizando la precisión y el rendimiento de cada uno de ellos entrenados utilizando métricas apropiadas.
- Comparación entre modelos seleccionados, examinando el rendimiento de los modelos de clasificación usados.
- Análisis e interpretación de los resultados obtenidos de las clasificaciones realizadas por el modelo.
- Conclusiones y trabajo futuro. Consistirá en resumir los resultados obtenidos y presentar conclusiones sobre la eficacia y las limitaciones del enfoque de clasificación de galaxias mediante el uso de aprendizaje profundo.

En el siguiente diagrama de Gantt, se muestra de manera visual la secuencia y duración de las tareas que se han llevado a cabo para la elaboración de este proyecto. Las tareas se han clasificado en colores para su fácil identificación.




Figura 1.2: Diagrama de Gantt

Capítulo 2

Estado del Arte y Conceptos

El objetivo principal de este capítulo es realizar un análisis exhaustivo del estado del arte en la clasificación de galaxias. Se introducirán conceptos como visión por computador, clasificación y segmentación de imágenes...

El estado del arte proporciona una visión general de los enfoques existentes y los desafíos que aún persisten en el campo de la clasificación de galaxias. Se revisarán técnicas de Deep Learning en la clasificación de galaxias, como las redes neuronales convolucionales (CNN) y las redes neuronales profundas.

En cuanto a los conceptos del Deep Learning, se explicarán los fundamentos teóricos y arquitecturas clave de las redes neuronales utilizadas en la clasificación de imágenes. Se abordarán conceptos como las capas convolucionales, las capas de pooling, aprendizaje supervisado y no supervisado... Además, se presentarán herramientas y bibliotecas populares utilizadas para implementar y entrenar modelos de Deep Learning en el contexto de la clasificación de galaxias.

Este capítulo proporcionará una base sólida para comprender los avances actuales en la clasificación de galaxias mediante el uso de técnicas de Deep Learning. A partir de esta revisión del estado del arte y la comprensión de los conceptos fundamentales.

2.1. Visión por Computador

La visión por computador es una disciplina interdisciplinaria que combina el procesamiento de imágenes, el aprendizaje automático y la inteligencia artificial para permitir que las máquinas vean, comprendan e interpreten el contenido visual de las imágenes o vídeos de manera similar a como lo hacen los seres humanos.

La visión por computador se aplica en una amplia gama de campos, incluyendo la medicina, la industria automotriz, la seguridad, la robótica, la realidad virtual..., en nuestro caso se utilizará en astronomía.

La visión por computador aborda una amplia gama de tareas, que incluyen:

- **Detección de objetos:** La detección de objetos implica identificar y localizar la presencia de objetos específicos dentro de una imagen o vídeo. Esto puede involucrar la detección de rostros, vehículos, personas u otros objetos de interés.




Figura 2.1: Ejemplo de detección de objetos

- **Seguimiento de objetos:** El seguimiento de objetos implica rastrear y seguir el movimiento de un objeto específico a lo largo de una secuencia de imágenes o vídeo. Esto puede ser útil en aplicaciones de vigilancia, realidad aumentada o análisis de comportamiento.
- **Reconocimiento de objetos:** El reconocimiento de objetos implica identificar y clasificar diferentes clases de objetos en una imagen o vídeo. Puede abarcar desde reconocimiento de gestos y reconocimiento de caracteres hasta reconocimiento de objetos más complejos, como animales o edificios.
- **Reconocimiento de escenas:** El reconocimiento de escenas se centra en la identificación y clasificación de diferentes tipos de entornos o escenas

en una imagen o vídeo, como paisajes urbanos, interiores de edificios o paisajes naturales.

- Segmentación semántica: La segmentación semántica implica asignar una etiqueta semántica a cada píxel en una imagen, lo que permite identificar y distinguir diferentes objetos y regiones en la imagen.




Figura 2.2: Ejemplo de segmentación semántica

- Estimación de pose: La estimación de pose se refiere a determinar la posición y orientación de un objeto en el espacio tridimensional a partir de una imagen o vídeo. Puede ser utilizado, por ejemplo, para el seguimiento de movimientos humanos o para la navegación autónoma de robots.

2.2. Clasificación de imágenes

La clasificación de imágenes es un problema común en la visión por computador, que implica asignar etiquetas o categorías a las imágenes en función de su contenido. Puede ser utilizado en una amplia gama de aplicaciones, como reconocimiento de objetos, detección de rostros, diagnóstico médico, detección de spam, entre otros.

Existen diferentes enfoques para la clasificación de imágenes, como son la clasificación basada en características extraídas donde se extraen característica o descriptores de las imágenes y se utilizan para entrenar un clasificador y el aprendizaje profundo del que hablaremos en profundidad más adelante.

Es importante tener en cuenta que la clasificación de imágenes es un problema complejo y los resultados pueden variar según el conjunto de datos, la calidad de las imágenes, el tamaño del conjunto de entrenamiento y la elección del algoritmo o modelo utilizado. Además, es fundamental contar con un conjunto de datos etiquetado y representativo para el entrenamiento del clasificador.

2.3. Segmentación de imágenes

La segmentación de imágenes es una tarea fundamental en el campo de la visión por computador, que implica dividir una imagen en regiones significativas o segmentos con características similares. La segmentación permite identificar y separar objetos o regiones de interés en una imagen, lo que facilita el análisis y procesamiento posterior.

Existen diferentes enfoques para la segmentación de imágenes, algunos de ellos son:

- Segmentación basada en umbrales: Este enfoque es uno de los más simples y se basa en la aplicación de umbrales en los valores de los píxeles de una imagen. Los píxeles se clasifican como pertenecientes a un segmento si cumplen ciertas condiciones de umbral en relación con sus valores de intensidad, color u otras características. Es útil cuando los objetos de interés en la imagen presentan una diferencia clara en sus características con respecto al fondo.
- Segmentación por regiones: Este enfoque se basa en la agrupación de píxeles similares en regiones coherentes. Se utilizan algoritmos de agrupamiento, como la agrupación jerárquica, el agrupamiento basado en crecimiento de regiones o el agrupamiento basado en grafos, para asignar los píxeles a las regiones correspondientes.
- Segmentación basada en bordes: En este enfoque, se detectan los bordes o contornos en una imagen y se utilizan como base para la segmentación. Se aplican operadores de detección de bordes, como el algoritmo de detección de bordes de diferencia de gaussianas (DoG), para identificar cambios abruptos en la intensidad de los píxeles que indican la presencia de bordes.
- Segmentación semántica: Este enfoque busca asignar etiquetas semánticas a los píxeles de una imagen, es decir, asignar una clase o categoría a cada píxel en función de su contenido. Se utilizan técnicas avanzadas de aprendizaje automático, como redes neuronales convolucionales (CNN). La segmentación semántica es útil cuando se requiere una comprensión detallada de la estructura y el contenido de una imagen.

Estos son solo algunos enfoques comunes utilizados en la segmentación de imágenes. Existen más métodos y algoritmos, y la elección del enfoque depende del problema específico y las características de la imagen que se desea segmentar.

2.4. Conceptos básicos Deep Learning

El Deep Learning, también conocido como aprendizaje profundo, es una rama de la inteligencia artificial que se basa en el uso de redes neuronales artificiales con múltiples capas para aprender y extraer representaciones de alto nivel de los datos. A diferencia del aprendizaje automático tradicional, el Deep Learning permite que los modelos aprendan automáticamente a través de capas de abstracción, lo que les permite capturar características complejas y realizar tareas más sofisticadas.

En la clasificación de imágenes, el Deep Learning ha demostrado ser altamente efectivo. Las imágenes de galaxias suelen ser grandes, complejas y con una gran cantidad de detalles. Las técnicas de Deep Learning pueden extraer características relevantes y aprendidas automáticamente, lo que permite una clasificación más eficiente. A continuación, se presentan algunos conceptos básicos del Deep Learning y su aplicación en la clasificación de imágenes:

2.4.1. Redes Neuronales Convolucionales (CNN)

Las redes neuronales convolucionales son un tipo de arquitectura de Deep Learning diseñada específicamente para el procesamiento de imágenes. Utilizan capas convolucionales para extraer características locales y aprendidas automáticamente, y capas de pooling para reducir la dimensionalidad de los datos. Las CNN han logrado grandes avances en la clasificación de imágenes, incluidas las imágenes astronómicas.

Las redes convolucionales aplican filtros de convolución a las entradas. Se aprenden los parámetros de los filtros, siendo un filtro convolucional aquel que aplica una función de convolución sobre la entrada. El filtro convolucional de una 1D, 2D o múltiples dimensiones. Un ejemplo de filtro convolucional 2D es el siguiente:

$$S(m, n) = (X * Y)(m, n) = \sum_j \sum_i X(i, j) Y(m - i, n - j) \quad (2.1)$$

2.4.2. Capas de pooling

Las capas de pooling, son conocidas como capas de submuestreo. Como se ha comentado anteriormente, estas capas ayudan a reducir la dimensio-

nalidad espacial de las características extraídas, lo que a su vez disminuye la cantidad de parámetros en el modelo y ayuda a controlar el sobreajuste u overfitting (concepto en la ciencia de datos que ocurre cuando un modelo estadístico se ajusta exactamente a sus datos de entrenamiento, siendo incapaz de generalizarse bien a nuevos datos). Además, las capas de pooling proporcionan cierta invarianza a pequeñas traslaciones y deformaciones en las características.

La operación principal de las capas de pooling es aplicar una función de agrupación como:

- Max Pooling: que reduce los datos calculando el máximo, dentro de una ventana de filtro indicada.
- Average Pooling: que reduce los datos calculando su media dentro de una ventana de filtro indicada.

Esta función se aplica a regiones locales no solapadas de las características de entrada. La región de agrupación se desliza a través de las características, generalmente con un tamaño de ventana y un desplazamiento definidos, manteniendo las características más relevantes.




Figura 2.3: Ejemplo de Average Pooling

Las capas de pooling han sido ampliamente utilizadas en el procesamiento de imágenes y han demostrado ser útiles en tareas de clasificación de imágenes, un ejemplo es el artículo "ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems" donde se hace uso de las capas para mejorar el rendimiento de la red. Al reducir la dimensionalidad de las características, las capas de pooling permiten una representación más compacta y manejable de la información, lo que facilita el procesamiento posterior y mejora la eficiencia computacional.

2.4.3. Transferencia de aprendizaje

La transferencia de aprendizaje es una técnica en la que se aprovecha un modelo pre-entrenado en un conjunto de datos grande y general, como ImageNet, y se ajusta para una tarea específica, como la clasificación de galaxias. Esto permite aprovechar el conocimiento previo del modelo en la extracción de características y acelerar el proceso de entrenamiento.

2.4.4. Aumento de datos

El aumento de datos es una técnica comúnmente utilizada en la clasificación de imágenes astronómicas mediante Deep Learning. Consiste en generar nuevas instancias de imágenes a partir de las existentes mediante transformaciones como rotaciones, cambios de escala, desplazamientos, entre otros. Esto ayuda a aumentar la diversidad de datos de entrenamiento y a mejorar la generalización del modelo.

2.4.5. Validación cruzada

En clasificación de imágenes, es esencial evaluar el rendimiento del modelo de Deep Learning de manera robusta. La validación cruzada es una técnica que divide el conjunto de datos en subconjuntos de entrenamiento y prueba, permitiendo evaluar el rendimiento del modelo en diferentes particiones de los datos y evitar el sobreajuste.

2.4.6. Frameworks y bibliotecas

Existen varios frameworks y bibliotecas populares para implementar y entrenar modelos de Deep Learning en la clasificación de imágenes astronómicas, como PyTorch. Estas herramientas proporcionan una interfaz fácil de usar y optimizada para el cálculo numérico, lo que facilita la implementación y el entrenamiento de modelos de Deep Learning.

2.5. Aprendizaje Supervisado

El aprendizaje supervisado es una técnica en el campo del aprendizaje automático que implica entrenar un modelo utilizando datos etiquetados,

es decir, datos que contienen ejemplos de entrada junto con sus correspondientes salidas deseadas. El objetivo es que el modelo aprenda una función o mapeo entre las entradas y las salidas, de modo que pueda predecir las salidas para nuevas entradas no vistas previamente.

En el aprendizaje supervisado, se trabaja con un conjunto de datos de entrenamiento que consiste en pares de ejemplos de entrada-salida. El modelo se ajusta a estos datos de entrenamiento mediante la búsqueda de una función o un conjunto de parámetros que minimicen una medida de error o pérdida. Una vez que el modelo ha sido entrenado, se puede utilizar para realizar predicciones en nuevos datos de prueba.




Figura 2.4: Ejemplos de patrones (imagen, dígito)

2.6. Aprendizaje No Supervisado

El aprendizaje no supervisado es una rama del aprendizaje automático en la que se busca descubrir patrones o estructuras ocultas en los datos sin la ayuda de etiquetas o información de salida conocida. A diferencia del aprendizaje supervisado, en el que se tienen datos etiquetados, en el aprendizaje no supervisado se trabaja con datos no etiquetados y el objetivo principal es explorar la estructura subyacente de los datos.

De forma matemática, mientras que en aprendizaje supervisado contamos con patrones de datos (x, y) , donde x es un array de atributos numéricos, e y un valor numérico que se quiere predecir como $y = f(x)$, en aprendizaje no supervisado, sólo se dispone de patrones de datos de entrada x_i y se trata de intentar abstraer los datos para su mejor comprensión.

Un ejemplo gráfico del objetivo del aprendizaje no supervisado sería el siguiente:

Donde cada uno de los colores identificaría a cada uno de los grupos en los que se intenta crear subconjuntos de datos.




Figura 2.5: Ejemplo de aprendizaje no supervisado

Capítulo 3

Análisis

Con el crecimiento exponencial de datos visuales en diversas aplicaciones, la clasificación de imágenes se ha convertido en una herramienta esencial para extraer información útil y tomar decisiones basadas en el contenido visual.

La clasificación de imágenes implica asignar etiquetas o categorías a las imágenes en función de su contenido visual. El objetivo es entrenar un modelo que pueda aprender patrones y características distintivas en las imágenes para distinguir diferentes clases.

La clasificación de imágenes presenta varios desafíos, como la variabilidad en la apariencia de los objetos, la presencia de ruido o distracciones en las imágenes y la necesidad de extraer características relevantes para la clasificación. Sin embargo, con el avance de las técnicas de aprendizaje automático y el uso de modelos de aprendizaje profundo, se han logrado avances significativos en este campo.

En este análisis, exploraremos enfoques y técnicas para resolver el problema de clasificación. Utilizaremos un conjunto de datos etiquetado que contiene imágenes de diferentes clases y emplearemos técnicas para entrenar un modelo que pueda clasificar las imágenes correctamente.

La clasificación de imágenes es un campo en constante evolución, y los avances en algoritmos y técnicas están mejorando continuamente la precisión y el rendimiento de los modelos de clasificación. Al explorar este problema, no solo estaremos abordando un desafío actual y relevante, sino que también estaremos contribuyendo al crecimiento y desarrollo de la visión por computador y sus diversas aplicaciones prácticas.

3.1. Dataset

En esta sección, proporcionaremos una descripción detallada del conjunto de datos utilizado para entrenar y evaluar diversos modelos y algoritmos destinados a la clasificación de imágenes de galaxias.

Galaxy Zoo es un proyecto de ciencia ciudadana en línea que invita a personas de todo el mundo a participar en la clasificación de galaxias. Fue lanzado en 2007 como una colaboración entre astrónomos y científicos ciudadanos para abordar el desafío de analizar un gran número de imágenes de galaxias.

El objetivo principal de Galaxy Zoo es clasificar galaxias en diferentes categorías según su forma y estructura. Los participantes del proyecto tienen acceso a imágenes reales de galaxias. Luego, utilizando una interfaz en línea, los voluntarios clasifican las galaxias según su forma, determinando si son espirales, elípticas u otras categorías.




Figura 3.1: Ejemplos de imágenes de galaxias extraídas de Galaxy Zoo

La clasificación precisa y detallada de las galaxias es esencial para comprender la formación y evolución de las mismas. Los resultados obtenidos de las clasificaciones de los participantes de Galaxy Zoo se combinan y analizan para ayudar a los astrónomos a obtener información valiosa sobre la población galáctica, la interacción entre galaxias y otros fenómenos astronómicos.

El proyecto Galaxy Zoo ha generado una gran cantidad de datos valiosos y ha brindado a personas de diferentes orígenes la oportunidad de contribuir directamente al avance de la ciencia.

3.1.1. Conjunto de imágenes

Dentro del proyecto Galaxy Zoo se ha utilizado el conjunto de imágenes de Galaxy Zoo 2. Este conjunto contiene 243.456 imágenes en formato .jpg, cada una de ellas nombrada con un id asociado.

3.1.2. Archivo CSV

Este archivo es una base de datos que contiene información de clasificaciones de galaxias. Cada fila del archivo CSV representa una clasificación de una galaxia específica y las columnas proporcionan diferentes atributos y características asociadas a esa clasificación.

A continuación se describe el significado de algunas de estas columnas:

- OBJID: identificador único a cada galaxia en el conjunto de datos.
- RA y DEC: coordenadas de la galaxia en el sistema de coordenadas astronómicas
- P_EDGE: probabilidad asignada de que el borde de una galaxia sea nítido o definido

Además de los ejemplos de columnas nombrados anteriormente, en particular para la clasificación de galaxias que nos ocupa este TFG, se ha trabajado específicamente con las columnas:

- SPIRAL
- ELLIPTICAL
- UNCERTAIN

Donde cada una de ellas tiene el valor 0 ó 1, lo que nos indica el tipo de la galaxia que es. Es decir, una de las tres columnas tiene el valor 1 y las otras dos el valor 0.

3.1.3. Archivo json

El archivo JSON de Galaxy Zoo 2 es un formato de archivo que contiene datos estructurados en formato JSON (JavaScript Object Notation) relacionados con las galaxias.

Este archivo contiene información detallada sobre cada galaxia, incluyendo los atributos y las respuestas asociadas a cada clasificación. Por ejemplo, puede contener información sobre la forma de la galaxia, la presencia de características específicas, como brazos espirales o núcleos, y otras características relevantes.

El formato JSON es ampliamente utilizado para representar datos estructurados, lo que lo hace adecuado para almacenar y transmitir datos.

En nuestro caso, este archivo nos sirve para la creación de máscaras para cada una de las imágenes, necesarias para el proceso de segmentación de imágenes. De él se obtienen los puntos $x's$ e $y's$ que definen el límite de cada galaxia.

En la segmentación de imágenes, una máscara es una imagen binaria que se utiliza para indicar las regiones de interés o los objetos de una imagen original. Consiste en asignar un valor de 0 (negro) a los píxeles que no forman parte del objeto de interés y un valor de 1 (blanco) a los píxeles que pertenecen al objeto.

La máscara se utiliza como una guía para separar o aislar los objetos de interés del resto de la imagen en aplicaciones de segmentación. Al aplicar la máscara a la imagen original, se conservan únicamente los píxeles que corresponden al objeto, mientras que los píxeles fuera de la máscara se descartan o se consideran como fondo.



Figura 3.2: Ejemplo de imagen y su correspondiente máscara

3.2.

